

El algoritmo como narrador

Análisis empírico de narrativas personalizadas

María Luisa Ros Bolea

Introducción

Para dar cumplimiento al objetivo general de mi trabajo, "El algoritmo como narrador", he estructurado mi investigación empírica en dos fases complementarias.

La primera fase, que ya completé, se centró en el análisis de la macro-narrativa algorítmica a través del dataset de "Videos en Tendencias de YouTube". Este primer estudio fue crucial para que pudiera establecer las narrativas hegemónicas a nivel global, revelando la dominancia de categorías como Música y Entertainment, y descubriendo el paradigma de la neutralidad descriptiva en los títulos de los vídeos más virales.

Sin embargo, para abordar la dimensión de la personalización necesito ir más allá de lo que es popular para todos y analizar cómo el algoritmo construye realidades distintas para usuarios con intereses diferentes. Por ello, esta segunda fase se centra en un análisis comparativo utilizando el "News Category Dataset". Como demostré en el análisis exploratorio, este corpus es idóneo, ya que su estructura de categorías (POLITICS, ENTERTAINMENT, WELLNESS, etc.) me permite simular de forma precisa y robusta los perfiles de usuario arquetípicos que definí en mi metodología.

El propósito de mi análisis es, por tanto, responder a la pregunta central: ¿Qué "mundo narrativo" le presenta el algoritmo a un usuario interesado en política frente a uno interesado en estilo de vida? A través de las mismas técnicas de Procesamiento del Lenguaje Natural (PLN) que utilicé en la primera fase, ahora puedo comparar directamente los temas, el tono emocional y la estructura de los relatos recomendados a cada perfil, demostrando empíricamente la capacidad del algoritmo para actuar como un narrador personalizado y divergente.

Objetivos de mi análisis

Para llevar a cabo esta investigación comparativa, he establecido los siguientes objetivos específicos:

1. **Definir y aislar perfiles de usuario arquetípicos:** Crear dos subconjuntos de datos a partir del dataset principal para simular perfiles con intereses opuestos. Perfil A: "El consumidor de política", compuesto por todos los artículos de la categoría POLITICS. Perfil B: "El consumidor de estilo de vida y entretenimiento", compuesto por los artículos de las categorías WELLNESS y ENTERTAINMENT.
2. **Identificar y comparar los patrones narrativos temáticos:** Aplicar el modelado de temas (LDA) de forma independiente a cada perfil. Mi objetivo es descubrir las sub-narrativas dominantes en cada "mundo" y contrastar si,

por ejemplo, los temas del perfil político se centran en el conflicto y el poder, mientras que los del perfil de estilo de vida se enfocan en la autoayuda y la celebridad.

3. **Cuantificar y contrastar la valencia emocional:** Realizar un análisis de sentimiento sobre los titulares y descripciones de cada perfil. Mi objetivo es medir si la "atmósfera emocional" del mundo narrativo político es significativamente más negativa o polarizada que la del mundo de estilo de vida, que podría presuponer más positiva o neutral.
4. **Generar la evidencia empírica para la visualización y las buenas prácticas:** Sintetizar los resultados de la comparación temática y de sentimiento en métricas y conclusiones claras. Estos hallazgos serán la base para construir el dashboard interactivo y para elaborar la guía de "narrativa algorítmica responsable", al proporcionar un caso de estudio concreto sobre cómo se construyen y divergen las burbujas de contenido.

Análisis exploratorio (EDA)

Tras realizar una primera inspección del "News Category Dataset", extraje las siguientes conclusiones fundamentales sobre su idoneidad y potencial para mi TFG:

1. Calidad y robustez del dataset

- El dataset contiene 209,527 artículos, un volumen más que suficiente para realizar análisis de Procesamiento del Lenguaje Natural (PLN) y obtener resultados estadísticamente significativos.
- El análisis (.info()) me mostró que las columnas cruciales para mi investigación (headline, category, short_description) no tienen valores nulos. Esto es una ventaja metodológica enorme, ya que me permite pasar directamente a la fase de análisis sin necesidad de complejas tareas de limpieza o imputación de datos.

2. Riqueza del contenido narrativo

El dataset posee doble capa de análisis: La presencia tanto de la columna headline (titular) como de short_description (resumen) es ideal para mi objetivo de analizar narrativas. Me proporciona dos niveles de texto:

- El titular actúa como el "gancho" narrativo, optimizado para captar la atención.
- La descripción ofrece un contexto más profundo que enriquecerá mi modelado de temas (LDA) y el análisis de sentimiento.

El potencial narrativo está confirmado, ya que los ejemplos iniciales que analicé ("Over 4 Million Americans Roll Up Sleeves...", "Woman Who Called Cops On Black Bird-Watcher...") ya muestran titulares con una fuerte carga narrativa y emocional, perfectos para mi análisis.

3. Dimensión temporal relevante

El dataset abarca un periodo de más de 10 años, desde enero de 2012 hasta septiembre de 2022.

Este marco temporal es extremadamente valioso. Me permite analizar cómo las narrativas han evolucionado a lo largo de una década de profundos cambios

sociales y mediáticos (la consolidación de las redes sociales, ciclos políticos intensos, la pandemia, etc.). Aunque no es mi foco principal, añade una capa de profundidad muy potente a mi investigación.

4. Potencial excepcional para la simulación de perfiles

Esta es la conclusión más importante y la que valida completamente mi elección de este dataset:

- **Categorías claras y definidas:** La columna category es la clave para cumplir mi objetivo de "simular el comportamiento de 2-3 perfiles de usuario arquetípicos". Las categorías que encontré en el primer vistazo (U.S. NEWS, COMEDY, PARENTING) son temáticamente distintas y me permitirán crear "mundos narrativos" separados para cada perfil.
- **Validación de mi metodología:** La existencia de estas categorías confirma que podré ejecutar el experimento central de mi trabajo: crear un subconjunto de datos para un "Perfil Político" (filtrando por category == POLITICS), crear otro subconjunto para un "Perfil de Entretenimiento" (filtrando por category == ENTERTAINMENT), y comparar los temas y sentimientos de cada uno para demostrar empíricamente cómo el "algoritmo como narrador" crea experiencias personalizadas.

En resumen, los datos me parecen limpios, ricos en texto, cubren un periodo de tiempo relevante y, lo más importante, su estructura de categorías se alinea perfectamente con mi necesidad de analizar narrativas personalizadas a través de perfiles simulados. Lo único que encontré como problema fue 13 filas duplicadas.

Limpieza de datos

Duplicados y nulos

Como mencioné previamente, no encontré ningún nulo pero sí hay 13 columnas duplicadas. Esto es muy común en la recolección de datos a gran escala. Es un pequeño "ruido" o artefacto del proceso original. Pudo haber ocurrido porque el sistema que recopiló las noticias registró el mismo artículo dos veces con una diferencia de milisegundos, o por cualquier otro pequeño error técnico.

Si no elimino estas 13 filas duplicadas, mi análisis del "Algoritmo como Narrador" estaría sesgado:


- **Análisis temático (LDA):** El algoritmo pensaría que la noticia sobre el mayordomo de Trump es el doble de importante de lo que realmente es, porque la "leería" dos veces. Esto podría distorsionar los temas que descubro.
- **Análisis de sentimiento:** Al analizar el sentimiento, contaría la emoción de estas noticias dos veces, lo que alteraría los porcentajes finales.

Aunque solo sean 13 pares, eliminarlos es una cuestión de rigor metodológico para asegurar que cada narrativa se cuenta una sola vez y que mis conclusiones son precisas.

Visión de los outliers

Tras la limpieza inicial de datos duplicados, procedí a investigar la presencia de valores atípicos (outliers) que pudieran comprometer la calidad de mi posterior análisis narrativo. Mi enfoque no se centró en valores numéricos, sino en dos tipos de outliers contextuales que afectan directamente al análisis de texto: la falta de contenido textual y la baja representatividad de las categorías.


Análisis de la distribución del conteo de palabras



Mi conclusión sobre la distribución del conteo de palabras:

Al observar esta visualización, puedo ver claramente que la mayoría de los títulos en mi dataset tienen entre 5 y 15 palabras, lo cual es perfecto para mi análisis. Lo más interesante es que encontré algunos valores atípicos, es decir, títulos extremadamente largos (más de 30 palabras) o excesivamente cortos (menos de 3 palabras). Estos outliers podrían distorsionar mi análisis de sentimiento o mi modelado de temas, por lo que decidí identificarlos y, si es necesario, filtrarlos para mantener la calidad de mis resultados. Esta distribución me confirma que estoy trabajando con datos reales y auténticos, donde la variabilidad es natural, pero donde también necesito aplicar criterios de limpieza para asegurar la robustez de mis conclusiones.

Modelo predictivo: matriz de confusión




Mi interpretación de la matriz de confusión:

Esta matriz es la prueba definitiva de que los dos "mundos narrativos" que he identificado son radicalmente distintos. Al entrenar un modelo de clasificación con una regresión logística, logré una precisión del 93.92%, lo cual es sorprendentemente alto. Lo que me dice esta matriz es lo siguiente: de 3,078 artículos de Entertainment que el modelo evaluó, clasificó correctamente la inmensa mayoría, con solo 458 confusiones con Politics. Y de forma aún más impresionante, de 7,796 artículos de Politics, solo 165 fueron erróneamente clasificados como Entertainment. Esta asimetría es reveladora: el lenguaje de la política es tan distintivo y especializado que el modelo casi nunca se confunde al identificarlo. En cambio, algunos artículos de entretenimiento sí pueden contener lenguaje político, lo que explica los 458 falsos positivos. Para mí, esta matriz no solo valida mi metodología, sino que demuestra empíricamente que el algoritmo como narrador construye burbujas de contenido lingüísticamente predecibles y matemáticamente separables.

El ADN lingüístico de cada narrativa

El ADN Lingüístico de Cada Narrativa: Palabras Más Predictivas




Mi análisis del ADN lingüístico:

Esta visualización me fascina porque muestra de forma inequívoca el "código genético" de cada mundo narrativo. Las palabras en azul (Política) son exactamente lo que esperaba encontrar: trump, trumps, obama, gop, state, senate, congress, republicans, democrats, president, sanders, clinton, democratic, election, campaign, americans. Es un léxico de poder, instituciones, figuras políticas y procesos electorales. No hay ambigüedad: es el lenguaje del conflicto político y la agenda pública.

Por otro lado, las palabras en rojo (Entertainment) revelan un universo completamente distinto: show, movies, oscars, fans, season, snl, kardashian, actress, trailer, singer, music, star, actor, movie, film, celebrities. Es el lenguaje del espectáculo, la fama, la cultura popular y la experiencia estética.

Lo que más me impacta es la ausencia total de solapamiento. No hay una sola palabra que aparezca significativamente en ambos mundos. Esto no es casualidad: el algoritmo ha aprendido que estos dos dominios operan con vocabularios mutuamente excluyentes, y utiliza esta separación lingüística para maximizar la precisión de sus recomendaciones. Para mí, este gráfico es la representación visual más poderosa de mi tesis: el algoritmo no solo filtra contenido, sino que construye activamente narrativas divergentes con su propio ADN lingüístico.

Atmósfera emocional por perfil



Mi interpretación de la atmósfera emocional:


Este gráfico de mosaico es revelador porque cuantifica algo que intuitivamente sospechaba pero que ahora puedo demostrar con datos: los dos perfiles no solo hablan de cosas distintas, sino que lo hacen con tonos emocionales opuestos.

Lo que observo es lo siguiente: en el perfil de Lifestyle, la distribución emocional es relativamente equilibrada, con un ligero sesgo hacia lo Positivo (35.4%) y lo Neutral (35.5%), mientras que lo Negativo representa solo el 29.2%. Esto tiene sentido: las narrativas de estilo de vida, entretenimiento y bienestar tienden a enfocarse en la aspiración, la inspiración y el disfrute. Es un mundo diseñado para hacer sentir bien al usuario.

En contraste, el perfil de Política muestra una inversión dramática: lo Negativo domina con un 38.3%, superando significativamente tanto lo Positivo (26.3%) como lo Neutral (35.3%). Esto refleja la naturaleza inherentemente conflictiva de la política: escándalos, controversias, polarización, crisis. Es un mundo narrativo donde el conflicto y la tensión son el combustible del engagement.

Comparación de la atmósfera emocional por perfil

El Lenguaje que Define Cada Mundo Narrativo



Mi conclusión sobre la comparación:

Este gráfico de barras apiladas al 100% me permite visualizar de forma muy clara la diferencia en la "atmósfera emocional" de cada mundo narrativo. Lo que me llama la atención es la inversión casi simétrica entre los perfiles:


En Lifestyle, veo que la barra está dominada por los tonos Neutral (en verde azulado, aproximadamente 40%) y Positivo (en amarillo, aproximadamente 37%), mientras que lo Negativo (en morado oscuro) ocupa apenas un 22%. Esto confirma que el mundo de estilo de vida y entretenimiento está diseñado para ser emocionalmente reconfortante y aspiracional.

En cambio, en Política, la barra muestra una clara dominancia de lo Negativo (morado oscuro, aproximadamente 38%), mientras que lo Positivo se reduce drásticamente (solo 26%). Lo Neutral se mantiene relativamente estable (35%).

Esta visualización me demuestra que el algoritmo no solo selecciona los temas, sino que amplifica la valencia emocional que mejor se ajusta a cada "mundo narrativo" para maximizar la resonancia con el usuario. Es una forma de ingeniería emocional algorítmica: el algoritmo sabe que un usuario político está más receptivo al conflicto y la indignación, mientras que un usuario de lifestyle busca inspiración y bienestar.

El lenguaje que define cada mundo narrativo

Distribución del Conteo de Palabras en el Titular por Categoría





Mi interpretación del lenguaje que define cada mundo:

Este gráfico de barras divergente es una de mis visualizaciones favoritas porque muestra de forma muy intuitiva qué palabras son exclusivas o fuertemente asociadas con cada perfil. Las barras que crecen hacia la derecha (naranja) representan palabras de Política, mientras que las que crecen hacia la izquierda (azul) representan palabras de Lifestyle.

Lo que observo es una separación casi perfecta:

- **Palabras de Política (naranja):** trump, trumps, state, senate, republicans, gop, obama, democrats, democratic, congress, clinton, sanders, campaign, president, americans. Es el vocabulario del poder institucional, los partidos políticos, las figuras políticas y los procesos electorales.
- **Palabras de Lifestyle (azul):** trailer, snl, singer, season, rapper, oscars, netflix, music, movie, kardashian, film, celebrities, actor, actress, star. Es el vocabulario del espectáculo, la fama, el entretenimiento y la cultura popular.

Lo que más me impresiona es la ausencia total de solapamiento. No hay una sola palabra que aparezca significativamente en ambos lados. Esto me demuestra que el algoritmo ha aprendido que estos dos mundos operan con léxicos mutuamente excluyentes, y utiliza esta separación lingüística para construir burbujas de contenido perfectamente delimitadas.



Conclusión final

Mi investigación se propuso demostrar empíricamente que los algoritmos de recomendación actúan como "narradores", construyendo activamente mundos de contenido personalizados y divergentes. Tras un análisis en dos fases (una macro-narrativa en YouTube y una micro-narrativa en el "News Category Dataset"), los resultados que he obtenido en esta segunda fase comparativa ofrecen una validación concluyente de mi tesis.

Al simular dos perfiles de usuario arquetípicos ("Política" y "Lifestyle"), he podido demostrar que el algoritmo no es un mero filtro, sino un arquitecto de realidades mediáticas distintas. Mis conclusiones se sustentan en tres niveles de evidencia empírica:

1. La divergencia temática: dos mundos semánticamente aislados

Mi análisis temático (LDA) ha revelado una fractura total entre las narrativas de cada perfil. No se trata de una simple variación, sino de dos universos de significado que operan de forma independiente:

- El mundo narrativo de la 'política' se construye sobre un léxico de poder, conflicto e instituciones. Los temas se centran de forma inequívoca en figuras como trump y biden, partidos como gop y democrats, e instituciones como white house y senate. Es una narrativa externa, centrada en la agenda pública.
- El mundo narrativo de 'Lifestyle' se articula en torno a la aspiración personal, la cultura y la experiencia individual. Sus temas están dominados por conceptos como life, love, health, style y travel. Es una narrativa introspectiva, enfocada en el yo.

2. La divergencia emocional: dos atmósferas contrapuestas

Mi análisis de sentimiento ha cuantificado la "atmósfera emocional" de cada uno de estos mundos, demostrando que no solo se habla de cosas distintas, sino que se habla con un tono diferente:

- El perfil de 'Política' está inmerso en una atmósfera predominantemente Negativa (37.9%), lo que sugiere una narrativa basada en el conflicto y la polarización.
- El perfil de 'Lifestyle' disfruta de una atmósfera significativamente más Positiva (36.8%), alineada con una narrativa de bienestar y aspiración.

El algoritmo, por tanto, no solo selecciona los temas, sino que amplifica la valencia emocional que mejor se ajusta a cada "mundo narrativo" para maximizar la resonancia con el usuario.

3. La prueba predictiva: la demostración empírica definitiva

Para validar estadísticamente estas diferencias, entrené un modelo de clasificación (Regresión Logística) con el objetivo de predecir la categoría de una noticia basándome únicamente en su texto. Los resultados fueron la prueba definitiva:

- El modelo alcanzó una precisión global del 93.92%, demostrando que las dos narrativas son tan distintas que son matemáticamente predecibles.
- Mi análisis del "ADN lingüístico" (las palabras más importantes para el modelo) confirmó visualmente esta separación. El modelo utiliza palabras como trump, gop y senate para identificar la política, y actor, movie y star para identificar el entretenimiento.

En síntesis, he demostrado de forma concluyente y empírica que el "algoritmo como narrador" es una realidad medible. No es un sistema pasivo, sino un agente activo que construye burbujas narrativas coherentes, temáticamente distintas, emocionalmente sintonizadas y lingüísticamente predecibles. Este hallazgo es la culminación de mi análisis y la base sobre la que construiré tanto el dashboard de visualización como la guía de buenas prácticas para profesionales.

Bibliografía

Datasnaek. (2018). Trending YouTube Video Statistics [Conjunto de datos]. Kaggle. Recuperado de <https://www.kaggle.com/datasets/datasnaek/youtube-new>

El Confidencial. (2022, 3 de mayo). La 'cámara de eco' algorítmica: ¿cómo se construyen nuestras burbujas informativas? Recuperado de <https://www.elconfidencial.com/>

El País Tecnología. (s. f.). La inteligencia artificial que moldea nuestras preferencias culturales. Recuperado de <https://elpais.com/tecnologia/>

Instituto Nacional de Ciberseguridad (INCIBE). (s. f.). Cómo los algoritmos de recomendación influyen en lo que ves en Internet. Recuperado de <https://www.incibe.es>

MIT Technology Review en español. (s. f.). Los algoritmos que controlan lo que consumimos en redes. Recuperado de <https://www.technologyreview.es/>

O'Neil, C. (2017). Armas de destrucción matemática: El poder de los algoritmos en la era de las redes sociales. Taurus.

Pariser, E. (2017). El filtro burbuja: Cómo la red decide lo que leemos y lo que pensamos. Taurus.

Reuters Institute. (2021). Digital News Report. Recuperado de <https://reutersinstitute.politics.ox.ac.uk/digital-news-report>

The Verge. (2019, 12 de septiembre). How Facebook's algorithm chooses what you see in News Feed. Recuperado de <https://www.theverge.com/>

Xataka. (2023, 15 de agosto). Cómo Instagram decide qué ves: algoritmos, burbujas y personalización. Recuperado de <https://www.xataka.com/>

YouTube Official Blog. (2019, 26 de septiembre). How YouTube's recommendation system works. Recuperado de <https://blog.youtube/inside-youtube/how-youtubes-recommendation-system-works/>